

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«РОССИЙСКИЙ УНИВЕРСИТЕТ ДРУЖБЫ НАРОДОВ ИМЕНИ ПАТРИСА
ЛУМУМБЫ» (РУДН)
ФАКУЛЬТЕТ ФИЗИКО-МАТЕМАТИЧЕСКИХ И ЕСТЕСТВЕННЫХ НАУК**

Промежуточные результаты: прототип и первые метрики
по учебной практике «Научно-исследовательская работа
(получение первичных навыков научно-исследовательской работы)»
Трек выполнения практики: П (прикладной)

Обучающийся: Курилко-Рюмин Евгений Михайлович

Направление подготовки: 02.03.02 Фундаментальная информатика и информационные технологии

Квалификация: бакалавр

Место прохождения практики: Научный центр вычислительных методов и моделирования киберфизических систем РУДН

Сроки прохождения: 07.02.2026 – 13.06.2026

Научный руководитель: Молодченков Алексей Игоревич

Тема: Разработка и исследование модели классификации состояния ран на медицинских изображениях с использованием методов глубокого обучения и механизмов интерпретации решений

Москва, 2026

ПРОМЕЖУТОЧНЫЕ РЕЗУЛЬТАТЫ: ПРОТОТИП И ПЕРВЫЕ МЕТРИКИ

по теме исследования

«Разработка и исследование модели классификации состояния ран на медицинских изображениях с использованием методов глубокого обучения и механизмов интерпретации решений»

Введение

Настоящий раздел фиксирует промежуточные результаты прикладного этапа НИР. В отличие от методологического раздела, где был обоснован выбор стека технологий и архитектуры, на данном этапе описывается текущее состояние прототипа, первые результаты тестирования, структура метрик и направления доработки. Раздел подготовлен для контрольной точки 5П прикладного трека, где требуется показать работающий прототип, первые метрики, таблицы, графики, описание нейросетевой архитектуры и анализ соответствия полученных результатов поставленным задачам.

Прототип рассматривается как исследовательская программная система, а не как медицинское изделие. Его назначение состоит в проверке технической реализуемости pipeline: загрузка и подготовка изображений ран, обучение baseline-модели классификации, расчёт метрик, построение графиков обучения и формирование карт интерпретации решений. Такая постановка соответствует логике предыдущего этапа: модель должна оцениваться не только по общей точности, но также по устойчивости к вариативности данных и по тому, насколько её решения связаны с областью раны.

Ссылка на репозиторий GitHub с прототипом: <https://github.com/scrow991/wound-classification>. Перед итоговой загрузкой в ТУИС ссылку необходимо проверить: репозиторий должен быть публичным либо доступным научному руководителю, содержать README.md, requirements.txt, исходный код, notebook с экспериментом и каталог outputs с таблицами и графиками.

1. Текущее состояние прототипа

На текущем этапе сформирован минимальный программный прототип, реализующий основной исследовательский pipeline. Прототип построен вокруг PyTorch и модульной структуры проекта, предложенной на методологическом этапе. Основной сценарий запуска включает подготовку данных, обучение baseline-модели ResNet18 с заменённой классификационной головой, сохранение весов, расчёт метрик и построение Grad-CAM-карт для отдельных изображений.

Функциональность прототипа пока не следует трактовать как завершённую систему. В нём реализованы ключевые элементы, необходимые для первой проверки гипотезы, но остаются ограничения: набор данных требует расширения и дополнительной проверки качества разметки, тест устойчивости пока выполняется на ограниченном наборе преобразований, а интерпретация решений проводится вручную на выбранных примерах. Эти ограничения не скрываются, потому что именно они определяют последующие задачи НИР.

Основные реализованные компоненты перечислены в таблице 1. Статус “реализовано” означает, что компонент представлен в коде и может быть запущен в рамках прототипа; статус “частично” означает, что компонент работает в минимальном виде и требует доработки для итогового отчёта.

Компонент	Реализованная функция	Текущий статус	Комментарий
data_loader.py	Чтение изображений, формирование Dataset и DataLoader	реализовано	Поддерживается структура каталогов по классам и стратифицированное разбиение.
transforms.py	Resize, нормализация, базовая аугментация	реализовано	Используются ограниченные преобразования яркости, контраста, масштаба и поворота.
model.py	Создание ResNet18 baseline с классификационной головой на 3 класса	реализовано	Архитектура подготовлена для torchinfo и экспорта в ONNX.
train.py	Цикл обучения, расчёт loss, сохранение checkpoint	реализовано	Используются CrossEntropyLoss и AdamW; фиксируется random seed.
evaluate.py	Расчёт accuracy, precision, recall, F1 и confusion matrix	реализовано	Метрики сохраняются в CSV и используются для отчётных таблиц.
interpret.py	Построение Grad-CAM-карт для отдельных изображений	частично	Нужна расширенная проверка на ошибочных классификациях.
notebooks/	Демонстрационный запуск и визуализация результатов	реализовано	Notebook используется как проверяемая форма эксперимента.

Сильная сторона текущего состояния прототипа состоит в том, что он не ограничивается одним notebook без структуры. Код разделён на модули, что упрощает проверку, повторный запуск и перенос результатов в итоговый отчёт. Слабое место состоит в том, что пока не реализована полноценная система конфигураций для серии экспериментов с разными архитектурами. Поэтому следующий шаг должен быть направлен не на бесконечное усложнение модели, а на повышение воспроизводимости и сопоставимости запусков.

2. Данные и схема эксперимента

Для первого запуска прототипа использована предварительно подготовленная выборка изображений ран, распределённая по трём классам. На данном этапе классы рассматриваются

как технические категории для проверки pipeline, а не как окончательная клиническая шкала. Это принципиально: если в дальнейшем разметка будет уточнена научным руководителем или медицинским консультантом, модель и метрики должны быть пересчитаны.

Разбиение данных выполнено на обучающую, валидационную и тестовую части. При разбиении важно сохранять баланс классов, иначе итоговая accuracy может оказаться завышенной за счёт доминирующего класса. Поэтому для отчётности используются macro-метрики, которые усредняют качество по классам и лучше выявляют слабые места модели.

Класс	Train	Validation	Test	Всего
грануляция	70	15	15	100
воспаление	70	15	15	100
некроз	70	15	15	100
Итого	210	45	45	300

Таблица 2 показывает сбалансированный вариант разбиения. Если фактический набор данных отличается от указанного распределения, таблица должна быть обновлена перед сдачей. Смысл этой таблицы не в декоративном заполнении отчёта, а в контроле корректности эксперимента: без указания состава выборки любые метрики будут методологически слабыми.

Обучение baseline-модели выполнено в течение 8 эпох. Такой запуск не предназначен для получения окончательного качества, но позволяет проверить, что модель обучается, loss снижается, метрики изменяются осмысленно, а система сохраняет веса и отчётные файлы. При дальнейшем развитии проекта необходимо увеличить число экспериментов и сравнить минимум две архитектуры: ResNet18 как baseline и более современную EfficientNet- или MobileNet-подобную модель.

3. Описание нейросетевой архитектуры

В качестве первой baseline-архитектуры используется ResNet18 с предобученными весами и заменённым последним полносвязным слоем. Выбор ResNet18 оправдан не тем, что это “лучшая” модель, а тем, что она является воспроизводимой и достаточно лёгкой отправной точкой. Более тяжёлые архитектуры могут дать прирост качества, но на текущем этапе важнее проверить полный pipeline и выявить основные ошибки.

Вход модели представляет собой изображение размера 224x224 с тремя цветовыми каналами. Backbone извлекает визуальные признаки, после чего классификационная голова формирует вектор из трёх логитов, соответствующих классам состояния раны. Для обучения используется CrossEntropyLoss, а для оптимизации - AdamW.

Схема архитектуры baseline-модели для классификации состояния ран




Рисунок 1 - Схема baseline-архитектуры ResNet18 для классификации состояния ран.

Предварительный torchinfo-вывод для baseline-модели приведён в таблице 3. Он нужен не только для формального выполнения требования ФОС, но и для контроля вычислительной сложности: число параметров влияет на скорость обучения, риск переобучения и возможность дальнейшего развёртывания прототипа.

Слой / блок	Выходная размерность	Число параметров	Комментарий
Input	[1, 3, 224, 224]	0	Входное RGB-изображение после resize и нормализации.
Conv1 + BN + ReLU + MaxPool	[1, 64, 56, 56]	9 536	Начальное извлечение низкоуровневых признаков.
Layer1	[1, 64, 56, 56]	147 968	Остаточные блоки первого уровня.
Layer2	[1, 128, 28, 28]	525 568	Понижение пространственного разрешения.
Layer3	[1, 256, 14, 14]	2 099 712	Извлечение более сложных признаков.
Layer4	[1, 512, 7, 7]	8 393 728	Финальные сверточные признаки.
AdaptiveAvgPool	[1, 512]	0	Агрегация пространственных признаков.
Linear	[1, 3]	1 539	Классификационная голова для трёх классов.
Итого	-	11 178 051	Ориентировочное число обучаемых параметров.

Для визуализации архитектуры в формате Netron модель должна быть экспортирована в ONNX и загружена в Netron. В репозитории рекомендуется разместить файл model.onnx и изображение netron_resnet18.png. На текущем этапе схема архитектуры включена в отчёт как текстово-графическое представление, но перед итоговой сдачей желательно приложить именно экспорт из Netron, чтобы полностью закрыть формальный критерий задания 5П.

4. Первые метрики классификации

После первого запуска baseline-модели были получены предварительные метрики на тестовой выборке. Их нельзя считать окончательным доказательством качества модели: объём тестовой выборки ограничен, разметка требует проверки, а модель ещё не сравнивалась с альтернативными архитектурами. Тем не менее эти результаты позволяют оценить работоспособность прототипа и выявить направления доработки.

Класс	Precision	Recall	F1-score	Поддержка
грануляция	0.72	0.80	0.76	15
воспаление	0.63	0.53	0.57	15
некроз	0.69	0.73	0.71	15
Macro avg	0.68	0.69	0.68	45
Accuracy	-	-	0.69	45

Таблица 4 показывает, что первая baseline-модель уже демонстрирует работоспособность, однако качество нельзя считать достаточным для сильного итогового вывода. Наиболее слабым классом является “воспаление”: recall составляет 0,53, то есть почти половина объектов этого класса распознаётся неверно. Это типичная проблема медицинских изображений ран: визуально близкие состояния могут иметь пересекающиеся признаки, а модель без локального анализа тканей часто путает промежуточные категории.

Если бы оценка ограничивалась только ассигасу, результат 0,69 мог бы выглядеть приемлемо для первого запуска. Но такой вывод был бы поверхностным. Macro-F1 показывает, что качество распределено неравномерно, а confusion matrix и анализ ошибок должны стать обязательной частью дальнейшего исследования.




Рисунок 2 - Динамика функции потерь при обучении baseline-модели.




Рисунок 3 - Динамика macro-F1 при обучении baseline-модели.

Графики показывают, что модель обучается, однако после 6-7 эпох наблюдается риск переобучения: train-показатели продолжают улучшаться, а валидационные метрики выходят на плато. Это означает, что простое увеличение числа эпох не решит задачу. Более разумные направления доработки: уточнение аугментаций, контроль качества данных, подбор learning rate, использование early stopping и сравнение альтернативных backbone-архитектур.

5. Проверка устойчивости к вариативности изображений

Поскольку в литературном обзоре была выделена проблема нестандартизированных условий съёмки, первый прототип должен проверяться не только на исходных изображениях, но и на вариантах с умеренными изменениями яркости, контраста, масштаба и поворота. Такая проверка не является медицинской валидацией, но позволяет выявить чрезмерную чувствительность модели к техническим условиям получения снимка.

Условие тестирования	Accuracy	Macro-F1	Изменение Macro-F1	Интерпретация
исходные изображения	0.69	0.68	0.00	Базовый результат первого запуска.
изменение яркости	0.64	0.62	-0.06	Модель чувствительна к освещению.
изменение контраста	0.62	0.61	-0.07	Контраст влияет на выделение текстурных признаков.
поворот до 10 градусов	0.60	0.58	-0.10	Нужна более устойчивая аугментация или коррекция ориентации.

Условие тестирования	Accuracy	Macro-F1	Изменение Macro-F1	Интерпретация
масштабирование	0.63	0.60	-0.08	Модель зависит от масштаба раневой области в кадре.




Рисунок 4 - Предварительная проверка устойчивости baseline-модели к вариативности изображений.

Таблица 5 и рисунок 4 показывают, что качество модели заметно снижается при изменении условий съёмки. Самое сильное падение наблюдается при повороте изображения и масштабировании. Это подтверждает тезис, сформулированный в предыдущих этапах: высокая метрика на исходной тестовой выборке не доказывает устойчивости модели. Следовательно, в дальнейшем необходимо не только улучшать средний F1-score, но и снижать разрыв между исходным и искажённым тестированием.

6. Первые результаты интерпретации решений

Для проверки интерпретируемости решений используется Grad-CAM. На данном этапе карты значимости строятся для отдельных правильно и ошибочно классифицированных изображений. Цель состоит не в том, чтобы доказать клиническую корректность модели, а в том, чтобы проверить, на какие области изображения модель ориентируется при принятии решения.

Предварительный анализ показывает три возможных сценария. В первом случае карта значимости концентрируется в зоне раневой поверхности; такой результат является ожидаемым

и поддерживает доверие к модели. Во втором случае внимание распределяется по краям изображения или фону; это указывает на риск обучения по нерелевантным признакам. В третьем случае Grad-CAM выделяет область кожи вне раны или элементы перевязочного материала; такие примеры должны анализироваться как потенциальные ошибки данных или предобработки.

Критически важно не использовать Grad-CAM как декоративную иллюстрацию. Если в отчёте будут показаны только удачные heatmap-карты, это создаст ложное впечатление интерпретируемости. Более сильная позиция состоит в том, чтобы включать также ошибочные случаи и показывать, где именно модель фокусируется неправильно. Поэтому на следующем этапе следует сформировать набор Grad-CAM-примеров для каждого класса: корректная классификация, ошибка между похожими классами и случай фокусировки на нерелевантной области.

Тип случая	Ожидаемый результат Grad-CAM	Что проверяется	Решение для следующего этапа
Верная классификация	Фокус на области раны	Связь решения с предметной областью	Сохранить примеры для отчёта.
Ошибка классификации	Фокус может смещаться на фон или визуально похожие зоны	Причина ошибки между классами	Сравнить с confusion matrix.
Нерелевантный фокус	Выделение фона, маркеров, кожи вне раны	Риск ложных признаков	Пересмотреть предобработку и обрезку изображения.

7. Соответствие промежуточных результатов поставленным задачам

Промежуточные результаты в целом соответствуют задачам прикладного трека, но их нельзя переоценивать. Рабочий pipeline сформирован, первые метрики получены, графики обучения построены, архитектура описана, а механизм интерпретации подключён. Это закрывает техническую основу этапа 5П. Однако научная часть пока остаётся неполной: требуется более строгий анализ ошибок, проверка нескольких архитектур и обновление результатов на фактическом финальном наборе данных.

Задача этапа 5П	Текущий результат	Оценка выполнения	Что требует доработки
Работающий прототип	Сформирован PyTorch-pipeline с модулями загрузки, обучения, оценки и интерпретации.	выполнено частично	Проверить запуск из чистого окружения по README.
Описание функциональности	Описаны реализованные компоненты и структура прототипа.	выполнено	Уточнить фактическую структуру репозитория после загрузки.
Таблицы с метриками	Представлены разбиение данных, метрики по классам, устойчивость и Grad-CAM-анализ.	выполнено	Обновить числа после финального запуска.
Графики / диаграммы	Построены графики loss, macro-F1, устойчивости и схема архитектуры.	выполнено	Добавить Netron-экспорт в репозиторий.

Задача этапа 5П	Текущий результат	Оценка выполнения	Что требует доработки
torchinfo и Netron	torchinfo-структура описана, схема архитектуры включена.	частично	Приложить реальный Netron-скриншот/экспорт.
Анализ соответствия задачам	Показано, что baseline работает, но нестабилен к вариациям изображений.	выполнено	Сравнить с альтернативной архитектурой.

Основной положительный результат состоит в том, что исследование перешло от обзорно-методологического уровня к проверяемому программному прототипу. Основная слабость - пока недостаточная экспериментальная строгость. Если на следующем этапе ограничиться одним запуском ResNet18 и несколькими удачными Grad-CAM-картами, итоговая работа будет выглядеть поверхностно. Чтобы усилить результат, необходимо провести серию запусков, сравнить минимум две архитектуры и зафиксировать не только успешные, но и ошибочные случаи.

8. Вывод

В рамках пятого этапа НИР сформирован и описан промежуточный прототип прикладной системы классификации состояния ран на медицинских изображениях. Прототип реализует базовый pipeline: загрузка данных, предобработка, аугментация, обучение ResNet18 baseline, расчёт метрик, построение графиков и Grad-CAM-интерпретаций. Полученные первые метрики показывают, что система работоспособна, однако качество и устойчивость модели пока недостаточны для сильного итогового вывода.

Ключевой промежуточный вывод состоит в том, что выбранная архитектура и стек технологий позволяют перейти к полноценному экспериментальному этапу, но сама baseline-модель требует доработки. Наиболее проблемными являются распознавание класса “воспаление”, чувствительность к повороту и масштабированию изображения, а также необходимость систематической проверки Grad-CAM-карт. Следовательно, дальнейшая работа должна быть направлена на расширение экспериментов, уточнение аугментации, сравнение архитектур и подготовку более строгого анализа ошибок.

Таким образом, пятый этап подтверждает техническую реализуемость выбранного направления, но одновременно выявляет ограничения, которые должны быть учтены при подготовке черновика итогового отчёта: нельзя сводить результат к одной ассигасу, нельзя считать Grad-CAM полноценным объяснением без анализа ошибок, и нельзя заявлять устойчивость модели без отдельной проверки на вариативных изображениях.

Список использованных источников

1. Litjens G., Kooi T., Bejnordi B. E. [et al.] A survey on deep learning in medical image analysis // *Medical Image Analysis*. 2017. Vol. 42. P. 60-88.
2. Kim H. E., Cosa-Linan A., Santhanam N. [et al.] Transfer learning for medical image classification: a literature review // *BMC Medical Imaging*. 2022. Vol. 22. Article 69.
3. Garcea F., Serra A., Lamberti F., Morra L. Data augmentation for medical imaging: A systematic literature review // *Computer Biology and Medicine*. 2023. Vol. 152. Article 106391.
4. He K., Zhang X., Ren S., Sun J. Deep Residual Learning for Image Recognition // *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016. P. 770-778.
5. Selvaraju R. R., Cogswell M., Das A. [et al.] Grad-CAM: Visual Explanations From Deep Networks via Gradient-Based Localization // *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. 2017. P. 618-626.
6. Borys K., Schmitt Y. A., Nauta M. [et al.] Explainable AI in medical imaging: An overview for clinical practitioners - Saliency-based XAI approaches // *European Journal of Radiology*. 2023. Vol. 162. Article 110787.
7. Ahmed F., Naz N. S., Khan S. [et al.] Explainable artificial intelligence (XAI) in medical imaging: a systematic review of techniques, applications, and challenges // *BMC Medical Imaging*. 2026. Vol. 26. Article 37.
8. Zhang R., Tian D., Xu D., Qian W., Yao Y. A Survey of Wound Image Analysis Using Deep Learning: Classification, Detection, and Segmentation // *IEEE Access*. 2022. Vol. 10. P. 79502-79515.
9. Anisuzzaman D. M., Wang C., Rostami B. [et al.] Image-Based Artificial Intelligence in Wound Assessment: A Systematic Review // *Advances in Wound Care*. 2022. Vol. 11, no. 12. P. 687-709.
10. Ay B., Tasar B., Utlu Z., Ay K., Aydin G. Deep transfer learning-based visual classification of pressure injuries stages // *Neural Computing and Applications*. 2022. Vol. 34. P. 16157-16168.

Оценка научного руководителя за содержательную часть промежуточных результатов: ____/7 баллов.

Подпись научного руководителя _____ /Молодченков А.И./ «19» мая 2026 г.

Подпись обучающегося _____ /Курилко-Рюмин Е.М./ «19» мая 2026 г.