

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«РОССИЙСКИЙ УНИВЕРСИТЕТ ДРУЖБЫ НАРОДОВ ИМЕНИ ПАТРИСА
ЛУМУМБЫ» (РУДН)**

ФАКУЛЬТЕТ ФИЗИКО-МАТЕМАТИЧЕСКИХ И ЕСТЕСТВЕННЫХ НАУК

Литературный обзор

по учебной практике «Научно-исследовательская работа
(получение первичных навыков научно-исследовательской работы)»

Обучающийся: Курилко-Рюмин Евгений Михайлович

Направление подготовки: 02.03.02 Фундаментальная информатика и
информационные технологии

Квалификация: бакалавр

Место прохождения практики: Научный центр вычислительных методов и
моделирования киберфизических систем РУДН

Сроки прохождения: 07.02.2026 – 13.06.2026

Научный руководитель: Молодченков Алексей Игоревич

Тема: Разработка и исследование модели классификации состояния ран на
медицинских изображениях с использованием методов глубокого обучения и
механизмов интерпретации решений

ЛИТЕРАТУРНЫЙ ОБЗОР

по теме исследования

*«Разработка и исследование модели классификации состояния ран на медицинских изображениях
с использованием методов глубокого обучения и механизмов интерпретации решений»*

Введение

Актуальность исследования обусловлена одновременно медицинскими и вычислительными факторами. С клинической точки зрения визуальная оценка состояния раны имеет принципиальное значение для выбора тактики лечения, контроля динамики заживления и своевременного выявления осложнений. Однако такая оценка нередко зависит от опыта специалиста, условий съёмки и субъективной интерпретации морфологических признаков. С вычислительной точки зрения задача осложняется высокой вариативностью изображений: различиями в освещении, ракурсе, масштабе, цветопередаче, наличии посторонних объектов на снимке и выраженным межклассовым сходством патологических состояний. В результате разработка устойчивой модели классификации состояния ран по медицинским изображениям представляет собой не частную инженерную задачу, а самостоятельную исследовательскую проблему, лежащую на пересечении медицинского анализа изображений, глубокого обучения и объяснимого искусственного интеллекта.

Общий контекст применения методов глубокого обучения в медицинской визуализации подробно описан в обзоре G. Litjens и соавт. [1], где показано, что сверточные архитектуры стали базовым инструментом для классификации, сегментации и детекции на медицинских изображениях. Вместе с тем из этого же направления следует принципиальное ограничение: успех моделей достигается не только за счёт архитектуры, но и за счёт качества данных, стандартизованности протоколов съёмки и корректно подобранных схем обучения. Для задач анализа ран это ограничение особенно существенно, поскольку доступные датасеты, как правило, меньше и менее стандартизованы, чем, например, наборы рентгенологических или томографических изображений.

Согласно требованиям учебной практики литературный обзор должен не просто перечислять публикации, а демонстрировать умение систематизировать подходы, критически сопоставлять их сильные и слабые стороны и подводить к выводу о необходимости дальнейшей разработки темы. Именно поэтому в настоящем обзоре акцент делается на трёх взаимосвязанных блоках: во-первых, на подходах глубокого обучения для медицинской классификации изображений; во-вторых, на работах, непосредственно посвящённых анализу изображений ран; в-третьих, на методах интерпретации решений модели и их ограничениях. Границы обзора охватывают прежде всего исследования, в которых решаются задачи классификации, сегментации или комплексной оценки ран по клиническим фотографиям, а также работы, задающие методологическую основу для выбора архитектуры, схемы обучения и способов объяснения решений.

1. Глубокое обучение в анализе медицинских изображений: методологическая база задачи

Современные исследования в области медицинского компьютерного зрения исходят из того, что глубокое обучение обеспечивает автоматическое извлечение признаков из визуальных данных и тем самым снижает зависимость от ручного конструирования дескрипторов. В этом заключается сильная сторона подхода, показанная в обзоре [1]: модели способны выявлять сложные пространственные и текстурные закономерности, которые трудно формализовать вручную. Однако универсальность этого тезиса часто переоценивается. Перенос успешных архитектур из общей компьютерной визуализации в медицину не гарантирует устойчивого результата, поскольку медицинские изображения характеризуются высокой ценой ошибки, ограниченными выборками и требованием воспроизводимости.

Важное место в литературе занимает transfer learning. По данным обзора Н. Е. Kim и соавт. [2], использование предобученных моделей позволяет повысить качество классификации при малом объёме размеченных данных и уменьшить вычислительные затраты на обучение. Для темы исследования это особенно релевантно: изображения ран редко представлены в объёмах, достаточных для обучения глубокой сети «с нуля». Сильная сторона transfer learning состоит в возможности использовать уже

сформированные низкоуровневые и частично среднеуровневые визуальные признаки. Однако слабость такого подхода заключается в доменном разрыве между естественными изображениями и медицинскими фотографиями. Иначе говоря, признаки, полезные на наборах ImageNet, не всегда оптимально отражают клинически значимые особенности раневой поверхности. Следовательно, сам факт использования предобученной модели не является обоснованием её пригодности; требуется отдельная проверка эффективности конкретной схемы fine-tuning на предметной выборке.

Ещё один опорный блок исследований связан с аугментацией данных. Систематический обзор F. Garcea и соавт. [3] показывает, что аугментация в медицинской визуализации действительно помогает бороться с переобучением и частично компенсировать дефицит данных. Для задач классификации состояния ран это особенно важно из-за дисбаланса классов и неоднородности визуальных условий съёмки. Тем не менее в литературе нередко игнорируется критически важное обстоятельство: не всякая аугментация клинически допустима. Геометрические преобразования, изменения яркости и контраста либо искусственное внесение шумов могут улучшать формальные метрики, но одновременно искажать признаки, существенные для медицинской интерпретации. Поэтому аугментация должна рассматриваться не как универсальный технический приём, а как контролируемый элемент исследовательского дизайна.

В качестве архитектурной основы значительная часть работ опирается на остаточные сети ResNet, предложенные К. Хе и соавт. [4]. Их достоинство заключается в устойчивом обучении глубоких моделей за счёт residual-связей и в наличии большого числа готовых реализаций и предобученных весов. Именно поэтому ResNet оправдана как baseline для последующего сравнения. Однако в литературе встречается типичная методологическая слабость: выбор ResNet часто производится по инерции, без доказательства, что именно эта архитектура оптимальна для конкретной медицинской задачи. Для настоящего исследования это означает, что ResNet может рассматриваться как исходная, но не как безусловно лучшая модель. Её использование требует сравнительной оценки и содержательного анализа ошибок.

2. Подходы к анализу изображений ран: от классических признаков к глубоким моделям

Предметно близкие исследования по анализу ран показывают эволюцию от систем, основанных на ручных признаках, к моделям глубокого обучения. В работе R. Mukherjee и соавт. [9] предложен framework автоматической классификации тканей хронических ран, ориентированный на выделение грануляции, некроза и налёта. Сильная сторона данного подхода состоит в предметной близости к заявленной теме: уже на раннем этапе развития направления была поставлена задача дифференциации состояний тканей по изображению. Однако слабость работы проявляется в ограниченности классических признаков и зависимостях от заранее выбранных процедур обработки. Такие системы, как правило, хуже переносятся на новые условия съёмки и менее гибки по сравнению с end-to-end моделями глубокого обучения.

Существенный вклад в систематизацию области вносит обзор D. M. Anisuzzaman и соавт. [8], посвящённый image-based искусственному интеллекту в оценке ран. Авторы показывают, что задачи анализа ран включают не только классификацию, но и измерение площади, сегментацию тканей, оценку динамики и прогнозирование. Достоинство этого обзора состоит в том, что он помещает классификацию состояния раны в более широкий клинический конвейер. Одновременно из него вытекает важный критический вывод: изолированная классификация без учёта локализации, типа ткани, размера и контекста снимка может оказаться слишком узкой постановкой. Следовательно, при разработке модели необходимо понимать её место в более общей системе цифровой оценки раневого процесса.

Отдельное направление представляют работы, в которых классификация тесно связана с сегментацией тканей. Так, D. Li и соавт. [10] исследуют сегментацию тканей на клинических фотографиях пролежней. Преимущество такого подхода очевидно: он позволяет перейти от глобального класса изображения к локальному анализу структуры раны. Это особенно ценно в тех случаях, когда на одном изображении одновременно присутствуют разные типы тканей и патологических зон. Однако сегментационные решения требуют более дорогой разметки и часто усложняют построение датасета.

Кроме того, они не отменяют задачи итоговой интерпретации клинического состояния, а лишь переносят её на следующий уровень анализа.

Работа D. Ramachandram и соавт. [11], посвящённая полностью автоматической сегментации тканей раны на мобильных устройствах, демонстрирует сильную прикладную сторону направления: модели постепенно выходят за пределы лабораторного прототипа. Её достоинство состоит в ориентации на реальные условия использования. Но именно здесь обнаруживается и ограничение: требования мобильного развёртывания заставляют балансировать между точностью и вычислительной эффективностью, а этот баланс не всегда совместим с глубокой клинической интерпретацией сложных состояний. Иными словами, прикладная реализуемость не гарантирует полноты диагностической информации.

Для задачи классификации стадий и состояний ран особенно важна работа В. Ау и соавт. [12], где используются предобученные CNN-модели для визуальной классификации стадий пролежней. Сильной стороной исследования является подтверждение того, что transfer learning применим и в очень близкой по постановке медицинской задаче. Однако слабость таких работ обычно состоит в том, что высокая итоговая метрика не раскрывает причин ошибок между визуально сходными классами, а также слабо отражает устойчивость модели к внешним изменениям — освещению, цвету кожи, фону, качеству камеры. Для настоящего исследования это означает, что одних только метрик ассурасу или F1 недостаточно; требуется анализ структуры ошибок и устойчивости модели.

Близкие результаты демонстрируют исследования мультимодальной классификации. В работе D. M. Anisuzzaman и соавт. [13], а затем в статье Y. Patel и соавт. [14] показано, что объединение изображения раны с дополнительным контекстом, в частности с её локализацией на теле пациента, способно повышать качество классификации. С методологической точки зрения это сильный аргумент против наивного предположения, что вся необходимая информация уже содержится в самом пиксельном представлении. В то же время эти работы выявляют и ограничение: если качество классификации существенно возрастает при добавлении внешнего контекста, значит чисто визуальная постановка задачи имеет принципиальные пределы.

Следовательно, модель классификации только по изображению должна оцениваться с пониманием этой границы применимости.

Наконец, более современные предметные исследования, например работа D. Reifs и соавт. [15] по распознаванию гипергрануляции, показывают, что область движется от грубых категорий к более тонкой дифференциации патологических состояний. Это усиливает практическую значимость направления, но одновременно делает задачу существенно сложнее: чем более тонким становится различие между классами, тем выше требования к данным, разметке, клинической валидации и интерпретации модели. Поэтому упрощённые постановки, удобные для машинного обучения, всё сильнее расходятся с реальной клинической сложностью.

3. Систематизация современных решений и их ограничения

Систематический обзор R. Zhang и соавт. [16] специально посвящён глубокому обучению в анализе изображений ран и охватывает задачи классификации, детекции и сегментации. Его ключевая ценность состоит в том, что он показывает неоднородность области: исследования используют разные датасеты, различные критерии качества и несопоставимые экспериментальные условия. Из этого следует важный критический вывод. В литературе нередко создаётся иллюзия быстрого прогресса, но прямое сравнение моделей часто некорректно, поскольку они обучаются и тестируются на разных выборках. Следовательно, утверждение о «лучшем» методе без унифицированной экспериментальной базы методологически слабо.

Практико-ориентированные исследования, связанные, например, с обнаружением и локализацией диабетических язв на мобильных устройствах [17] или с сочетанием текстурных признаков и CNN для классификации язв [18], подтверждают, что область активно развивается в сторону прикладных решений. Их достоинством является внимание к реальным сценариям использования и к инженерной устойчивости. Но именно эти работы выявляют типичный компромисс: чем сильнее модель адаптируется к конкретному сценарию, тем выше риск снижения переносимости на другие клинические контексты, типы ран и условия съёмки. Для исследования это означает необходимость различать локально хорошую модель и действительно обобщающую модель.

Часть литературы акцентирует внимание на измерении ран и вычислении количественных характеристик изображения [19], а также на более общих методах цифрового анализа биомедицинских изображений [21–25]. Эти источники полезны не столько как прямые аналоги предлагаемой системы, сколько как напоминание о том, что качество итоговой классификации определяется всей цепочкой обработки: стандартизацией изображения, подавлением шумов, выделением значимых признаков и корректной организацией входных данных. Слабое место многих современных end-to-end публикаций состоит в том, что этапы предобработки либо описаны поверхностно, либо считаются второстепенными. Для изображений ран такой подход рискован, поскольку вариативность съёмки может оказывать на модель влияние не меньшее, чем собственно морфология раны.

Таким образом, существующие решения можно условно разделить на четыре группы: классические методы с ручными признаками; модели transfer learning на основе готовых CNN; сегментационные и мультимодальные подходы; прикладные мобильные решения. У каждой группы есть преимущества, но ни одна не снимает всех ограничений одновременно. Классические методы интерпретируемые, но менее гибки. Глубокие модели сильнее в извлечении признаков, но хуже прозрачны. Сегментация даёт локальную структуру, но требует дорогой разметки. Мультимодальные подходы повышают качество, но усложняют сбор данных. Отсюда следует, что исследовательская задача не сводится к банальному выбору «самой точной» архитектуры; требуется найти сбалансированное решение между качеством, воспроизводимостью и интерпретируемостью.

4. Интерпретация решений модели: необходимость и пределы

Для медицинских приложений одной из центральных проблем остаётся доверие к модели. Высокая точность классификации сама по себе недостаточна, если невозможно понять, на какие визуальные признаки опиралось решение. В этом контексте базовой работой является статья R. R. Selvaraju и соавт. [5], где предложен метод Grad-CAM. Его достоинство заключается в наглядности: карта значимости позволяет визуально выделить области изображения, наиболее повлиявшие на предсказание сети. Для задачи классификации состояния ран это особенно привлекательно, поскольку даёт

возможность проверить, фокусируется ли модель на тканях раны, а не на фоне, размеченных маркерах или особенностях съёмки.

Однако отождествление карты значимости с полноценным объяснением было бы методологической ошибкой. Обзор К. Borys и соавт. [6] подчёркивает, что saliency-based методы в медицинской визуализации обладают ограниченной клинической интерпретируемостью: heatmap показывает коррелирующие области, но не раскрывает причинно-следственный механизм решения. Более того, визуальная привлекательность таких карт создаёт ложное ощущение прозрачности модели. Если исследователь ограничивается демонстрацией нескольких удачных примеров Grad-CAM без систематической проверки стабильности и клинической осмысленности, то интерпретация превращается в декоративный элемент, а не в исследовательский инструмент.

Сходный вывод следует из более общего систематического обзора F. Ahmed и соавт. [7], посвящённого ХАИ в медицинской визуализации. Авторы показывают, что в области отсутствует единый стандарт оценки качества объяснений: трудно формализовать, когда объяснение действительно повышает доверие и помогает врачу, а когда лишь маскирует ошибки модели. Для темы настоящего исследования это критически важно. Использование механизма интерпретации должно быть встроено в постановку задачи заранее, а не добавляться постфактум как средство визуального сопровождения уже обученной сети.

Следовательно, механизмы интерпретации в исследовании целесообразно рассматривать как средство валидации модели, а не как самостоятельное доказательство её корректности. Практический смысл имеют по меньшей мере три вопроса: во-первых, совпадают ли области внимания модели с клинически значимыми зонами раны; во-вторых, сохраняется ли интерпретация при изменении условий съёмки; в-третьих, помогают ли объяснения обнаруживать систематические ошибки классификации. Без ответа на эти вопросы включение Grad-CAM и сходных методов не решает проблему доверия.

5. Нерешённые задачи и обоснование собственного направления исследования

Проведённый анализ литературы показывает, что тема классификации состояния ран на медицинских изображениях действительно нуждается в дальнейшей разработке. Во-первых, в области сохраняется дефицит стандартизированных и достаточно крупных датасетов. Даже при наличии положительных результатов трудно оценить их переносимость, поскольку изображения собираются в разных условиях и нередко описываются по разным клиническим шкалам [8; 16]. Во-вторых, остаётся открытым вопрос о границах применимости purely visual-моделей: рост качества мультимодальных решений [13; 14] фактически указывает на то, что одного изображения часто недостаточно для надёжной клинической интерпретации. Во-третьих, интерпретируемость большинства решений пока остаётся частичной и во многом декларативной [6; 7].

Кроме того, заметно противоречие между двумя линиями развития литературы. С одной стороны, исследования стремятся к упрощению pipeline за счёт end-to-end глубоких моделей. С другой стороны, предметная специфика ран требует более детального учёта структуры изображения, типа ткани, условий съёмки и клинического контекста. Это противоречие означает, что «простая» классификация целого изображения часто оказывается либо слишком грубой, либо плохо объяснимой. Следовательно, исследовательская задача состоит не просто в повышении итоговой метрики, а в поиске модели, которая бы сочетала приемлемое качество классификации с интерпретируемостью и устойчивостью к вариативности данных.

С учётом рассмотренных работ обоснованным направлением собственного исследования представляется разработка модели классификации состояния ран на основе предобученной сверточной архитектуры с дообучением на специализированном наборе медицинских изображений, дополненной контролируемыми методами аугментации и механизмом интерпретации решений. Выбор именно такого направления оправдан тем, что transfer learning в близких медицинских задачах демонстрирует практическую эффективность [2; 12], а ResNet-подобные архитектуры обеспечивают надёжную базовую точку отсчёта [4]. Одновременно включение Grad-CAM или сходного

подхода необходимо не для внешней эффектности, а для проверки того, использует ли модель содержательные области изображения [5–7].

При этом более сильная версия исследовательской постановки состоит в следующем. Недостаточно показать, что модель классифицирует изображения ран с приемлемой точностью; требуется установить, в какой мере её решения опираются на клинически релевантные визуальные признаки и насколько эти решения устойчивы к вариациям входных данных. Такая постановка жёстче и научно содержательнее, чем обычное сравнение нескольких архитектур по одной агрегированной метрике. Она позволяет связать классификацию, обобщающую способность и интерпретируемость в единую исследовательскую рамку.

Исходя из этого, целесообразно ориентировать дальнейшее исследование на решение следующих взаимосвязанных задач: сравнение базовой и дообученной архитектур на специализированных данных; анализ влияния аугментации на качество и устойчивость предсказаний; исследование структуры ошибок между визуально сходными классами состояний раны; оценка карт интерпретации с точки зрения их клинической осмысленности. Такой план опирается на существующую литературу, но не дублирует её, поскольку направлен на преодоление выявленного разрыва между высокой формальной точностью и недостаточной объяснимостью современных моделей.

Заключение

Проведённый литературный обзор показал, что исследования в области анализа медицинских изображений создали прочную методологическую базу для применения глубокого обучения к задаче классификации состояния ран. Однако прямой перенос общих архитектур и стандартных практик машинного обучения в данную предметную область сталкивается с рядом серьёзных ограничений: малым объёмом и неоднородностью данных, сложностью стандартизации изображений, неоднозначностью границ между клиническими классами и недостаточной надёжностью постхок-интерпретаций. Анализ публикаций по wound image analysis, transfer learning и XAI подтверждает, что область развивается быстро, но пока не предлагает универсального решения, одновременно сочетающего высокую точность, устойчивость и клинически осмысленную интерпретируемость.

Итоговая исследовательская проблема может быть сформулирована следующим образом: каким образом разработать модель классификации состояния ран на медицинских изображениях, которая при ограниченном и неоднородном наборе данных обеспечивала бы приемлемое качество распознавания, сохраняла устойчивость к вариативности условий съёмки и позволяла бы интерпретировать решения в терминах клинически значимых областей изображения. Именно эта проблема обосновывает дальнейшее исследование и задаёт направление последующим этапам НИР — выбору архитектуры, методики обучения, средств интерпретации и критериев оценки.

Список использованных источников

1. Litjens G., Kooi T., Bejnordi B. E. [et al.] A survey on deep learning in medical image analysis // *Medical Image Analysis*. 2017. Vol. 42. P. 60-88.
2. Kim H. E., Cosa-Linan A., Santhanam N. [et al.] Transfer learning for medical image classification: a literature review // *BMC Medical Imaging*. 2022. Vol. 22. Article 69.
3. Garcea F., Serra A., Lamberti F., Morra L. Data augmentation for medical imaging: A systematic literature review // *Computer Biology and Medicine*. 2023. Vol. 152. Article 106391.
4. He K., Zhang X., Ren S., Sun J. Deep Residual Learning for Image Recognition // *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016. P. 770-778.
5. Selvaraju R. R., Cogswell M., Das A. [et al.] Grad-CAM: Visual Explanations From Deep Networks via Gradient-Based Localization // *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. 2017. P. 618-626.
6. Borys K., Schmitt Y. A., Nauta M. [et al.] Explainable AI in medical imaging: An overview for clinical practitioners - Saliency-based XAI approaches // *European Journal of Radiology*. 2023. Vol. 162. Article 110787.
7. Ahmed F., Naz N. S., Khan S. [et al.] Explainable artificial intelligence (XAI) in medical imaging: a systematic review of techniques, applications, and challenges // *BMC Medical Imaging*. 2026. Vol. 26. Article 37.

8. Anisuzzaman D. M., Wang C., Rostami B. [et al.] Image-Based Artificial Intelligence in Wound Assessment: A Systematic Review // *Advances in Wound Care*. 2022. Vol. 11, no. 12. P. 687-709.
9. Mukherjee R., Manohar D. D., Das D. K. [et al.] Automated tissue classification framework for reproducible chronic wound assessment // *BioMed Research International*. 2014. Vol. 2014. Article 851582.
10. Li D., Mathews C., Zamarripa C., Zhang F., Xiao Q. Wound tissue segmentation by computerised image analysis of clinical pressure injury photographs: a pilot study // *Journal of Wound Care*. 2022. Vol. 31, no. 8. P. 710-719.
11. Ramachandram D., Ramirez-GarciaLuna J. L., Fraser R. D. J. [et al.] Fully Automated Wound Tissue Segmentation Using Deep Learning on Mobile Devices: Cohort Study // *JMIR mHealth and uHealth*. 2022. Vol. 10, no. 4. Article e36977.
12. Ay B., Tasar B., Utlu Z., Ay K., Aydin G. Deep transfer learning-based visual classification of pressure injuries stages // *Neural Computing and Applications*. 2022. Vol. 34. P. 16157-16168.
13. Anisuzzaman D. M., Patel Y., Rostami B. [et al.] Multi-modal wound classification using wound image and location by deep neural network // *Scientific Reports*. 2022. Vol. 12. Article 20057.
14. Patel Y., Shah T., Dhar M. K. [et al.] Integrated image and location analysis for wound classification: a deep learning approach // *Scientific Reports*. 2024. Vol. 14. Article 7043.
15. Reifs D., Casanova L., Reig-Bolano R., Coda A. Detection of Hypergranulation Tissue in Chronic Wound Images Using Artificial Intelligence Algorithms // *Wound Repair and Regeneration*. 2026. Vol. 34, no. 1. Article e70125.
16. Zhang R., Tian D., Xu D., Qian W., Yao Y. A Survey of Wound Image Analysis Using Deep Learning: Classification, Detection, and Segmentation // *IEEE Access*. 2022. Vol. 10. P. 79502-79515.
17. Goyal M., Reeves N. D., Rajbhandari S., Yap M. H. Robust Methods for Real-Time Diabetic Foot Ulcer Detection and Localization on Mobile Devices // *IEEE Journal of Biomedical and Health Informatics*. 2019. Vol. 23, no. 4. P. 1730-1741.

18. Al-Garaawi N., Ebsim R., Alharan A. F. H., Yap M. H. Diabetic foot ulcer classification using mapped binary patterns and convolutional neural networks // Computers in Biology and Medicine. 2022. Vol. 140. Article 105055.
19. Li D., Mathews C. Automated measurement of pressure injury through image processing // Journal of Clinical Nursing. 2017. Vol. 26, no. 21-22. P. 3564-3575.
20. Ильясова Н. Ю., Куприянов А. В., Храмов А. Г. Информационные технологии анализа изображений в задачах медицинской диагностики. Москва: Радио и связь, 2012.
21. Акаева Т. М., Каменский А. В., Бородин Н. [и др.] Методы цифровой обработки медицинских оптических изображений для улучшения качества диагностики заболеваний: обзор // Компьютерная оптика. 2025. Т. 49, № 4. С. 593-623.

Подпись научного руководителя _____ /Молодченков
А.И./ «20» апреля 2026 г.

Подпись обучающегося _____ /Курилко-Рюмин Е.М./
«20» апреля 2026 г.